Java Collections Framework

André Matutat & Carsten Gips (HSBI)

TL;DR
Die Collection-API bietet verschiedene Sammlungen an, mit denen man Objekte speichern kann: Listen, Queues, Mengen, … Für diese Typen gibt es jeweils verschiedene Implementierungen mit einem spezifischen Verhalten. Zusätzlich gibt es noch Maps für das Speichern von Key/Value-Paaren, dabei wird für die Keys eine Hash-Tabelle eingesetzt.
Die Hilfs-Klasse `Collections` bietet statische Hilfs-Methoden, die auf `Collection<T>`s anwendbar sind.
Wenn man eigene Klassen in der Collection-API oder in Map benutzen möchte, sollte man den "equals-hashCode-Contract" berücksichtigen.
Videos

- VL Collections

---

1 Motivation: Snippet aus einer Klasse im PM-Dungeon

```
private List<Entity> entities = new ArrayList<>();

public void add(Entity e){
    if (!entities.contains(e)) entities.add(e);
}
```

Die war ein reales Beispiel aus der Entwicklung des PM-Dungeon.

Es wurde eine `ArrayList<T>` zum Verwalten der Entitäten genutzt. Allerdings sollte jedes Element nur einmal in der Liste vorkommen, deshalb wurde beim Einfügen einer Entität geprüft, ob diese bereits in der Liste ist.

Hier wird die **falsche Datenstruktur** genutzt!

Eine Liste kann ein Objekt mehrfach enthalten, eine Menge (*Set*) hingegen kann ein Objekt nur *einmal* enthalten.

2 Collection-API in Java

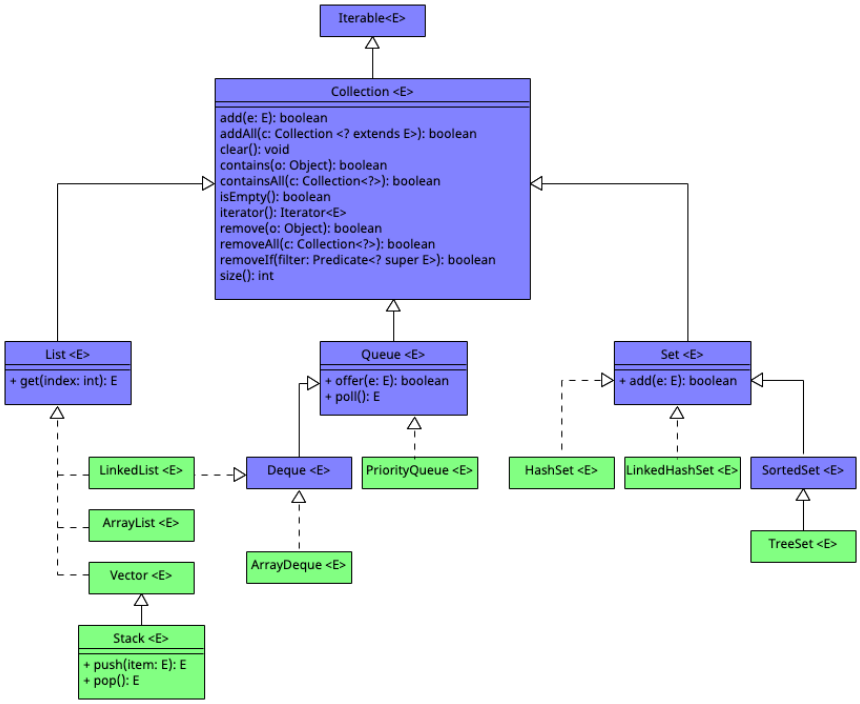

Hinweis: Die abstrakten (Zwischen-) Klassen wurden im obigen UML aus Gründen der Übersichtlichkeit *nicht* aufgeführt. Aus den selben Gründen sind auch nur ausgewählte Methoden aufgenommen worden.

Hinweis: Blau = Interface, Grün = Klasse.

`Collection<T>` ist ein zentrales Interface im JDK und stellt die gemeinsame API der Collection-Klassen dar. Klassen, die `Collection<T>` implementieren, speichern und verwalten eine Menge an Objekten.

Unter anderem gibt es die aus dem Modul “ADS” bekannten Datentypen wie Listen, Sets, Queues etc.

Man unterscheidet zwischen “sorted” (geordnete) Collections, welche eine bestimmte Reihenfolge der Elemente halten (Reihenfolge des Einfügens, aufsteigende Werte etc.) und “unsorted” (ungeordnete) Collections, welche keine bestimmte Reihenfolge halten.

Eine Übersicht, welche Collection welche Datenstruktur implementiert, kann unter “Collection Implementations” eingesehen werden.

- `List<T>`-Collections sind eine geordnete Liste an Objekten. Per Index-Zugriff können Objekte an jeder Stelle der Liste zugegriffen (oder hinzugefügt) werden.
- `Queue<T>`-Collections sind eine geordnete Sammlung von Objekten. Objekte können nur am Ende der Queue hinzugefügt werden und nur am Anfang der Queue (der Head) gelesen oder entnommen werden (“first in first out”).
- `Set<T>`-Collections sind eine (i.d.R.!) ungeordnete Menge an Objekten, die stets nur einmal in der Set enthalten sein können. In einem Set kann nicht direkt auf ein Objekt zugegriffen werden. Es kann aber geprüft werden, ob ein spezifisches Objekt in einer Set gespeichert ist.

Wichtig: `List<T>`, `Set<T>`, `Queue<T>` und `Map<K,V>` sind **Interfaces**, definieren also bestimmte Schnittstellen, die sich so wie aus ADS her bekannt verhalten. Diese können jeweils mit sehr unterschiedlichen Datenstrukturen implementiert werden und können dadurch auch intern ein anderes Verhalten haben (sortiert vs. nicht sortiert, Zugriffszeiten, ...).

Siehe auch Interface Collection.

3 Listen: *ArrayList*

```
private List<Entity> entities = new ArrayList<>();
```

Link zu einer netten Animation

Eine `ArrayList<T>` ist von außen betrachtet ein sich dynamisch vergrößerndes Array.

Intern wird allerdings ein statisches(!) Array benutzt. Wenn dieses Array voll ist, wird es um 50% vergrößert und alle Inhalte in das neue Array kopiert. Davon merkt man als Nutzer aber nichts.

Dank es Arrays kann auf ein Element per Index mit O(1) zugegriffen werden.

Wird ein Element aus der Liste gelöscht, rücken alle Nachfolgenden Einträge in der Liste einen Index auf (interner Kopiervorgang).

Deshalb ist eine `ArrayList<T>` effizient in der Abfrage und Manipulation von Einträgen, aber deutlich weniger effizient beim Hinzufügen und Löschen von Einträgen.

Per Default wird eine `ArrayList<T>` mit einem Array der Länge 10 angelegt, sobald das erste Element eingefügt wird. Man kann die Startgröße auch im Konstruktoraufruf der `ArrayList<T>` bestimmen: beispielsweise `new ArrayList<>(20)`.

Die Methoden einer `ArrayList<T>` sind nicht **`synchronized`**.

4 Listen: *LinkedList*

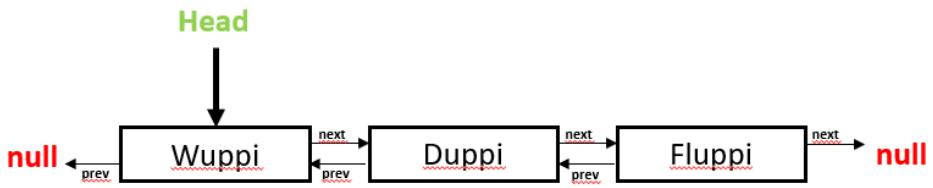

Link zu einer netten Animation

Eine `LinkedList<T>` ist eine Implementierung einer doppelt verketteten Liste (diese kennen Sie bereits aus ADS) in Java.

Jeder Eintrag wird als Knoten repräsentiert, der den eigentlichen Wert speichert und zusätzlich je einen Verweis auf den Vorgänger- und Nachfolger-Knoten hat.

Der Head der `LinkedList<T>` zeigt auf den Anfang der Liste, der Nachfolger des letzten Eintrag ist immer **`null`**.

Für den Zugriff auf ein Element muß man die `LinkedList<T>` traversieren und beginnt dabei am Anfang der Liste, deshalb ist ein Zugriff O(n).

Neue Elemente können effizient an das Ende der Liste eingefügt werden, indem der letzte Eintrag einen Verweis auf den neuen Knoten bekommt: O(1) (sofern man sich nicht nur den Start der Liste merkt, sondern auch das aktuelle Ende).

Wenn ein Element aus der Liste gelöscht wird, muss dieses zunächst gefundenen werden und die Liste danach neu verkettete werden: O(n).

Die Methoden einer `LinkedList<T>` sind nicht **`synchronized`**.

5 *Vector* und *Stack*

- `Vector<T>`:
  - Ein `Vector<T>` ähnelt einer `ArrayList<T>`
  - Das Array eines Vector wird jedoch verdoppelt, wenn es vergrößert wird
  - Die Methoden von `Vector<T>` sind **`synchronized`**

- `Stack<T>`:
  - Schnittstelle: “last in first out”-Prinzip
    * `push(T)`: Pushe Element oben auf den Stack
    * `pop(): T`: Hole oberstes Element vom Stack
  - Tatsächlich aber: **`class`** `Stack<E>` **`extends`** `Vector<E>`

6 Iterierbarkeit: *Iterable* und *Iterator*

```
private List <Entity> entities = new ArrayList<>();

for (Entity e : entities) { ... }
entities.forEach(x -> ...);
```

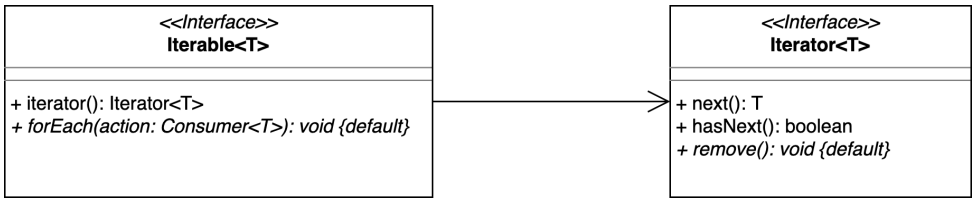

Die Klassen aus der Collection-API implementieren das Interface `Iterable<T>` und sind damit iterierbar. Man kann sie darüber in einer klassischen **`for`**-Schleife nutzen, oder mit der Methode `forEach()` direkt über die Sammlung laufen.

Intern wird dabei ein passender `Iterator<T>` erzeugt, der die Elemente der Sammlung schrittweise mit der Methode `next()` zurückgibt. Mithilfe eines Cursor merkt sich der Iterator, bei welchem Eintrag der Datenstruktur er aktuell ist. Mit der Methode `hasNext()` kann geprüft werden, ob noch ein weiteres Element über den Iterator aus der Datenstruktur verfügbar ist.

Mit `remove()` kann das letzte zurückgegebene Element aus der Datenstruktur entfernt werden. Diese Methode ist im Interface als Default-Methode implementiert.

Damit kann man die Datenstrukturen auf eine von der Datenstruktur vorgegebene Weise ablaufen, beispielsweise einen Binärbaum.

Link zu einer netten Animation

Man kann auch selbst für eigene Klassen einen passenden `Iterator<T>` implementieren, der zum Ablaufen der Elemente der eigenen Klasse genutzt werden kann. Damit die eigene Klasse auch in einer **`for`**-Schleife genutzt werden kann, muss sie aber auch noch `Iterable<T>` implementieren.

Beispiel: iterator_example.*

7 Hilfsklasse *Collections*

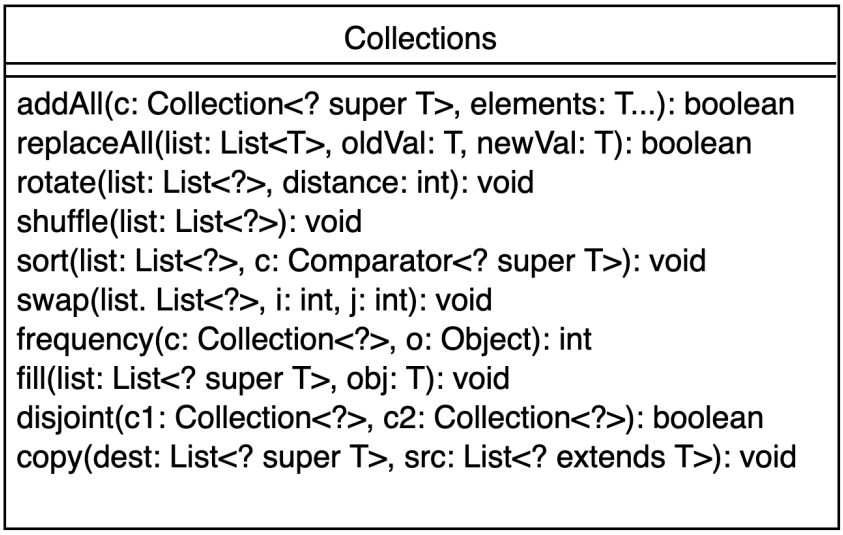

`Collections` ist eine Utility-Klasse mit statischen Methoden, die auf `Collection<T>`s ausgeführt werden. Diese Methoden nutzen das `Collection<T>`-Interface und/oder die `Iterable<T>`-Schnittstelle.

Siehe auch Class Collections.

Der Hintergrund für diese in Java nicht unübliche Aufsplittung in ein Interface und eine Utility-Klasse ist, dass bis vor kurzem Interface nur Schnittstellen definieren konnten. Erst seit einigen Java-Versionen kann in Interfaces auch Verhalten definiert werden (Default-Methoden). Aus heutiger Sicht würde man also vermutlich die statischen Methoden in der Klasse `Collections` eher direkt als Default-Methoden im Interface `Collection<T>` implementieren und bereitstellen, statt eine separate Utility-Klasse zu definieren.

8 *Map*

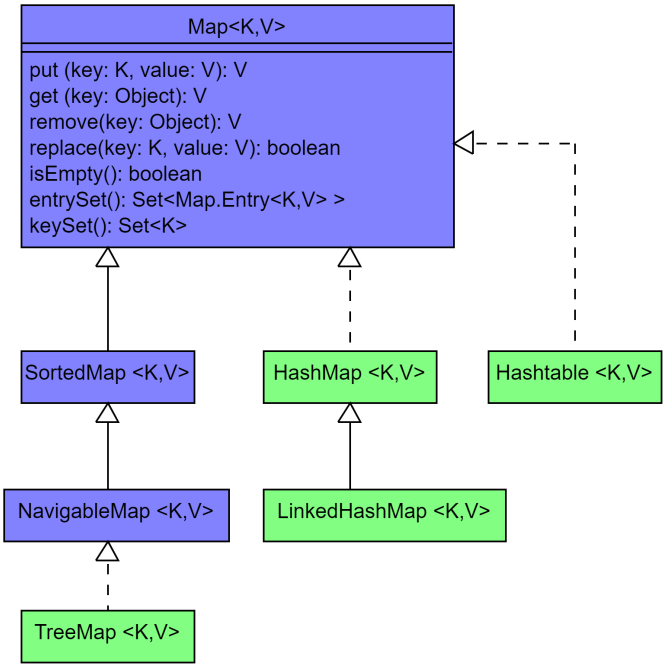

Hinweis: Die abstrakten (Zwischen-) Klassen wurden im obigen UML aus Gründen der Übersichtlichkeit *nicht* aufgeführt. Aus den selben Gründen sind auch nur ausgewählte Methoden aufgenommen worden.

Hinweis: Blau = Interface, Grün = Klasse.

Hinweis: Tatsächlich ist der Typ des Keys in den Methoden `get()` und `remove()` mit `Object` spezifiziert und nicht mit dem Typ-Parameter `K`. Das ist aus meiner Sicht eine Inkonsistenz in der API.

Eine `Map<K,V>` speichert Objekte als Key/Value-Paar mit den Typen `K` (Key) und `V` (Value).

Dabei sind die Keys in einer Map einzigartig und werden verwendet, um auf das jeweilige Value zuzugreifen. Ein Value kann entsprechend (mit unterschiedlichen Keys) mehrfach im einer Map enthalten sein.

Es gibt eine Reihe verschiedener Implementierungen, die unterschiedliche Datenstrukturen einsetzen, beispielsweise:

- `HashMap<K,V>` hält keine Ordnung in den Einträgen. Verwendet den Hashwert, um Objekte zu speichern. Zugriff auf Einträge in einer `HashMap` ist O(1).
- `LinkedHashMap<K,V>` hält die Einträge in der Reihenfolge, in der sie eingefügt wurden.
- `TreeMap<K,V>` hält die Einträge in aufsteigender Reihenfolge.

Siehe auch Interface Map.

9 *HashMap*

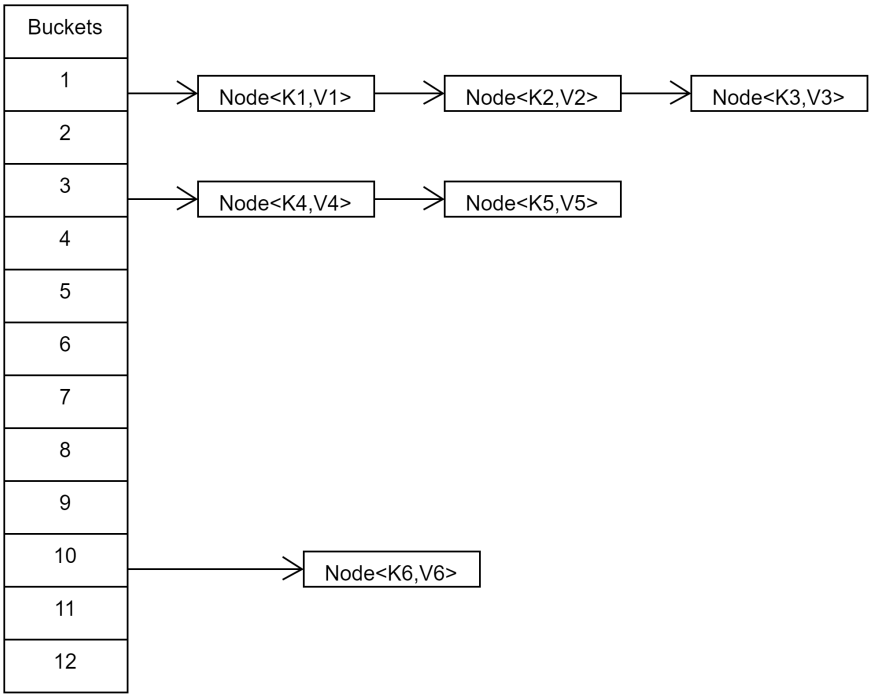

Eine `HashMap<K,V>` speichert die Elemente in mehreren einfach verketteten Listen. Dafür verwendet sie die innere Klasse `Node<K,V>`.

Die Heads, die auf den Anfang einer Liste zeigen, werden in "Buckets" gespeichert. Initial besitzt eine HashMap 12 Buckets, diese werden bei Bedarf erweitert.

Um einen Eintrag hinzufügen, wird zunächst aus dem `hashCode()` des Key-Objektes mithilfe der Hash-Funktion der Index des Buckets berechnet. Ist der Bucket gefunden, wird geprüft, ob das Objekt dort schon vorkommt: Mit dem `hashCode()` des Key-Objektes werden alle Objekte in der Liste des Buckets verglichen. Wenn es Einträge mit dem selben `hashCode()` in der Liste gibt, wird mit `equals` geprüft, ob die Key-Objekte identisch sind. Ist dies der Fall, wird der existierende Eintrag überschrieben, anderenfalls wird der neue Eintrag an das Ende der Liste hinzugefügt.

Implementierungsdetail: Wenn die Listen zu groß werden, wird die Hashtabelle neu angelegt mit ungefähr der doppelten Anzahl der Einträge (Buckets) und die alten Einträge per *Re-Hash* neu verteilt (vgl. Class HashMap).

`HashMap<K,V>` Methoden sind nicht **`synchronized`**.

`HashMap<K,V>` unterstützt einen **`null`**-Key. Es darf beliebig viele **`null`**-Values geben.

Die Unterklasse `LinkedHashMap<K,V>` kann Ordnung zwischen den Elementen halten. Dafür wird eine doppelt verkettete Liste verwendet.

Beispiel: hash_example.HashCodeExample

10 *Hashtable*

- Nicht zu verwechseln mit der Datenstruktur: Hash-Tabellen (!)
- `Hashtable<K,V>` ist vergleichbar mit einer `HashMap<K,V>`
- `Hashtable<K,V>`-Methoden sind **`synchronized`**
- Kein Key oder Value darf **`null`** sein

11 Spielregeln für *equals()*, *hashCode()* und *compareTo()*

11.1 *equals()*

`boolean` `equals(Object o)` ist eine Methode Klasse `Object` und wird genutzt, um Objekte auf Gleichheit zu prüfen. Die Default-Implementierung von `equals()` in `Object` vergleicht die beiden Objekte mit ==, gibt also nur dann **`true`** zurück, wenn die beiden zu vergleichenden Objekte die selbe Objekt-ID haben.

In der Praxis kann es sich anbieten, diese Methode zu überschreiben und eigene Kriterien für Gleichheit aufzustellen.

Dabei sind Spielregeln zu beachten (für nicht-**`null`** Objekte `x`, `y` und `z`):

1. Reflexivität: `x.equals(x)== true`
2. Symmetrie: `x.equals(y)== y.equals(x)`
3. Transitivität: Wenn `x.equals(y)== true` und `y.equals(z)== true`, dann auch `x.equals(z) == true`
4. Konsistenz: Mehrfache Aufrufe von `equals()` mit den selben Werten müssen immer das selbe Ergebnis liefern
5. `x.equals(null)== false`

11.2 *hashCode()*

Die Methode `int hashCode()` gibt den Hash-Wert eines Objektes zurück. Der Hash-Wert eins Objektes wird genutzt, um dieses in einen Hash-basierten Container abzulegen bzw. zu finden.

Der Rückgabewert der Methode `hashCode()` für ein Objekt bleibt über die Laufzeit einer Anwendung immer identisch, solange sich die zur Prüfung der Gleichheit genutzten Attribute nicht ändern.

11.3 *compareTo()*

Die Methode `int compareTo()` (Interface `Comparable<T>`) vergleicht Objekte und definiert damit eine Ordnung auf den Objekten. Während `equals()` für die Prüfung auf Gleichheit eingesetzt wird, wird `compareTo()` für die Sortierung von Objekten untereinander verwendet.

Spielregeln:

1. `x.compareTo(y)< 0` wenn `x` "kleiner" als `y` ist
2. `x.compareTo(y)> 0` wenn `x` "größer" als `y` ist
3. `x.compareTo(y)= 0` wenn `x` "gleich" als `y` ist
4. Symmetrie: `signum(x.compareTo(y))== -signum(y.compareTo(x))`
5. Transitivität: Wenn `x.compareTo(y)> 0` und `y.compareTo(z)> 0`, dann auch `x.compareTo(z)> 0`
6. Wenn `x.compareTo(y)== 0`, dann auch `signum(x.compareTo(z))== signum(y.compareTo(z))`

11.4 Der *equals()-hashCode()-compareTo()*-Vertrag

Wird `equals()` überschrieben, sollte auch `hashCode()` (passend) überschrieben werden.

1. Wenn `x.equals(y)== true`, dann *muss* auch `x.hashCode()== y.hashCode()`
2. Wenn `x.equals(y)== false`, *sollte* `x.hashCode()!= y.hashCode()` sein (Unterschiedliche `hashCode()`-Werte für unterschiedliche Objekte verbessern allerdings die Leistung von Hash-Berechnungen, etwa in einer `HashMap<K,V>`!)
3. Es wird sehr empfohlen, dass `equals()` und `compareTo()` konsistente Ergebnisse liefern: `x.compareTo(y)== 0` gdw. `x.equals(y)== true` (Dies *muss* aber nicht zwingend eingehalten werden, sorgt dann aber u.U. für unerwartete Nebeneffekte beim Umgang mit `Collection<T>` und `Map<K,V>`!)

Beispiel: hash_example.HashCodeExample

12 Überblick

						Mutate (einfügen oder löschen) am		
Collection	**Sortiert?**	**Duplikate erlaubt?**	**synchronized?**	**null erlaubt?**	**Peek**	**Anfang**	**Mitte**	**Ende**
LinkedList	ja	ja	nein	ja	O(n)	O(1)	O(n)	O(1)
ArrayList	ja	ja	nein	ja	O(1)	O(n)	O(n)	O(1)
Vector	ja	ja	ja	ja	O(1)	O(n)	O(n)	O(1)
Stack	ja	ja	ja	ja	O(1)	O(1)	-	-
ArrayDeque	ja	ja	nein	Nein	O(1)	O(1)	-	O(1)
PriorityQueue	ja	ja	nein	Nein	O(1)	-	-	O(1)
HashSet	nein	nein	nein	ja	O(1)	O(1)	O(1)	O(1)
LinkedHashSet	ja	nein	nein	ja	O(1)	O(1)	O(1)	O(1)
TreeSet	ja	nein	nein	nein	O(log n)	O(log n)	O(log n)	O(log n)
Hashtable	nein	Keine doppelten Keys	ja	Nein	O(1)	O(1)	O(1)	O(1)
HashMap	nein	Keine doppelten Keys	nein	Einmal als Key, Mehrfach als Value	O(1)	O(1)	O(1)	O(1)
LinkedHashMap	ja	Keine doppelten Keys	nein	Einmal als Key, Mehrfach als Value	O(1)	O(1)	O(1)	O(1)
TreeMap	ja	nein	nein	nein	O(log n)	O(log n)	O(log n)	O(log n)

Komplexitätswerte beziehen sich auf den Regelfall. Sonderfälle wie das Vergrößern des Array einer `ArrayList<T>` können für temporär erhöhte Komplexität sorgen (das ist dem O-Kalkül aber egal).

13 Wrap-Up

- Interface `Collection<T>`: Schnittstelle für Datenstrukturen/Sammlungen zur Verwaltung einer Menge von Objekten
- Klasse `Collections`: Statische Hilfs-Methoden (anwendbar auf `Collection<T>`s)
- `Iterable<T>` liefert einen `Iterator<T>` zur Iteration über eine `Collection<T>`
- Interface `Map<K,V>`: Speichern von Key/Value-Paaren
- `equals()`-`hashCode()`-`compareTo()`-Vertrag beachten

14 Zum Nachlesen

- Oracle Corporation (2022)

Lernziele

- k2: Was ist der Unterschied zwischen Collection<T> und List<T>?
- k2: Was ist der Unterschied zwischen einer List<T>, einer Queue<T> und einer Set<T>?
- k2: Nennen Sie charakteristische Merkmale von ArrayList<T>, LinkedList<T> und Vector<T>.
- k2: Was ist der Unterschied zwischen einer Queue<T> und einem Stack<T>?
- k2: Was ist eine Map<K,V>? Welche Vertreter kennen Sie?
- k3: Erklären Sie die ‘Spielregeln’ für die eigene Implementierung von equals().
- k3: Erklären Sie die ‘Spielregeln’ für die eigene Implementierung von hashCode().
- k3: Erklären Sie die ‘Spielregeln’ für die eigene Implementierung von compareTo().
- k3: Wie müssen und wie sollten equals(), hashCode() und compareTo() miteinander arbeiten?

Quizzes

- Quiz Collections (ILIAS)

Quellen

Oracle Corporation. 2022. „Learn Java“. 2022. https://dev.java/learn/.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 71232c0 (tooling: shift headings (use h1 as top-level headings), 2025-04-29)