Reguläre Ausdrücke

Carsten Gips (HSBI)

TL;DR
Mit Hilfe von regulären Ausdrücken kann man den Aufbau von Zeichenketten formal beschreiben. Dabei lassen sich direkt die gewünschten Zeichen einsetzen, oder man nutzt Zeichenklassen oder vordefinierte Ausdrücke. Teilausdrücke lassen sich gruppieren und über *Quantifier* kann definiert werden, wie oft ein Teilausdruck vorkommen soll. Die Quantifier sind per Default **greedy** und versuchen so viel wie möglich zu matchen.
Auf der Java-Seite stellt man reguläre Ausdrücke zunächst als `String` dar. Dabei muss darauf geachtet werden, dass ein Backslash im regulären Ausdruck im Java-String geschützt (*escaped*) werden muss, indem jeweils ein weiterer Backslash voran gestellt wird. Mit Hilfe der Klasse `java.util.regex.Pattern` lässt sich daraus ein Objekt mit dem kompilierten regulären Ausdruck erzeugen, was insbesondere bei mehrfacher Verwendung günstiger in der Laufzeit ist. Dem Pattern-Objekt kann man dann den Suchstring übergeben und bekommt ein Objekt der Klasse `java.util.regex.Matcher` (dort sind regulärer Ausdruck/Pattern und der Suchstring kombiniert). Mit den Methoden `Matcher#find` und `Matcher#matches` kann dann geprüft werden, ob das Pattern auf den Suchstring passt: `find` sucht dabei nach dem ersten Vorkommen des Patterns im Suchstring, `match` prüft, ob der gesamte String zum Pattern passt.
Videos

- VL RegExp
- Demo StringSplit
- Demo MatchFind
- Demo Quantifier
- Demo Groups
- Demo Backref

---

1 Suchen in Strings

Gesucht ist ein Programm zum Extrahieren von Telefonnummern aus E-Mails.

=> **Wie geht das?**

Leider gibt es unzählig viele Varianten, wie man eine Telefonnummer (samt Vorwahl und ggf. Ländervorwahl) aufschreiben kann:

```
030 - 123 456 789, 030-123456789, 030/123456789,
+49(30)123456-789, +49 (30) 123 456 - 789, ...
```

2 Definition Regulärer Ausdruck

> Ein **regulärer Ausdruck** ist eine Zeichenkette, die zur Beschreibung von Zeichenketten dient.

2.1 Anwendungen

- Finden von Bestandteilen in Zeichenketten
- Aufteilen von Strings in Tokens
- Validierung von textuellen Eingaben => “Eine Postleitzahl besteht aus 5 Ziffern”
- Compilerbau: Erkennen von Schlüsselwörtern und Strukturen und Syntaxfehlern

3 Einfachste reguläre Ausdrücke

Zeichenkette	Beschreibt
`x`	“x”
`.`	ein beliebiges Zeichen
`\t`	Tabulator
`\n`	Newline
`\r`	Carriage-return
`\\`	Backslash

3.1 Beispiel

- `abc` => “abc”
- `A.B` => “AAB” oder “A2B” oder …
- `a\\bc` => “a\bc”

3.2 Anmerkung

In Java-Strings leitet der Backslash eine zu interpretierende Befehlssequenz ein. Deshalb muss der Backslash i.d.R. geschützt (“escaped”) werden. => Statt “`\n`” müssen Sie im Java-Code “`\\n`” schreiben!

4 Zeichenklassen

Zeichenkette	Beschreibt
`[abc]`	“a” oder “b” oder “c”
`[^abc]`	alles außer “a”, “b” oder “c” (Negation)
`[a-zA-Z]`	alle Zeichen von “a” bis “z” und “A” bis “Z” (Range)

Zeichenkette	Beschreibt
`[a-z&&[def]]`	“d”,“e” oder “f” (Schnitt)
`[a-z&&[^bc]]`	“a” bis “z”, außer “b” und “c”: `[ad-z]` (Subtraktion)
`[a-z&&[^m-p]]`	“a” bis “z”, außer “m” bis “p”: `[a-lq-z]` (Subtraktion)

4.1 Beispiel

- `[abc]` => “a” oder “b” oder “c”
- `[a-c]` => “a” oder “b” oder “c”
- `[a-c][a-c]` => “aa”, “ab”, “ac”, “ba”, “bb”, “bc”, “ca”, “cb” oder “cc”
- `A[a-c]` => “Aa”, “Ab” oder “Ac”

5 Vordefinierte Ausdrücke

Zeichenkette	Beschreibt
`^`	Zeilenanfang
`$`	Zeilenende
`\d`	eine Ziffer: `[0-9]`
`\w`	beliebiges Wortzeichen: `[a-zA-Z_0-9]`
`\s`	Whitespace (Leerzeichen, Tabulator, Newline)
`\D`	jedes Zeichen außer Ziffern: `[^0-9]`
`\W`	jedes Zeichen außer Wortzeichen: `[^\w]`
`\S`	jedes Zeichen außer Whitespaces: `[^\s]`

5.1 Beispiel

- `\d\d\d\d\d` => “12345”
- `\w\wA` => “aaA”, “a0A”, “a_A”, …

6 Nutzung in Java

- `java.lang.String`:

```
public String[] split(String regex)
public boolean matches(String regex)
```

Demo: regexp.StringSplit

- `java.util.regex.Pattern`:

```
public static Pattern compile(String regex)
public Matcher matcher(CharSequence input)
```

  - Schritt 1: Ein Pattern compilieren (erzeugen) mit `Pattern#compile` => liefert ein Pattern-Objekt für den regulären Ausdruck zurück
  - Schritt 2: Dem Pattern-Objekt den zu untersuchenden Zeichenstrom übergeben mit `Pattern#matcher` => liefert ein Matcher-Objekt zurück, darin gebunden: Pattern (regulärer Ausdruck) und die zu untersuchende Zeichenkette

- `java.util.regex.Matcher`:

```
public boolean find()
public boolean matches()
public int groupCount()
public String group(int group)
```

  - Schritt 3: Mit dem Matcher-Objekt kann man die Ergebnisse der Anwendung des regulären Ausdrucks auf eine Zeichenkette auswerten

    Bedeutung der unterschiedlichen Methoden siehe folgende Folien

    `Matcher#group`: Liefert die Sub-Sequenz des Suchstrings zurück, die erfolgreich gematcht wurde (siehe unten "Fangende Gruppierungen")

Hinweis:

In Java-Strings leitet der Backslash eine zu interpretierende Befehlssequenz ein. Deshalb muss der Backslash i.d.R. extra geschützt ("escaped") werden.

=> Statt "`\n`" (regulärer Ausdruck) müssen Sie im Java-String "`\\n`" schreiben!

=> Statt "`a\\bc`" (regulärer Ausdruck, passt auf die Zeichenkette "a\bc") müssen Sie im Java-String "`a\\\\bc`" schreiben!

Demo: regexp.MatchFind

7 Unterschied zw. Finden und Matchen

- `Matcher#find`:

  Regulärer Ausdruck muss im Suchstring **enthalten** sein.
  => Suche nach **erstem Vorkommen**

- `Matcher#matches`:

  Regulärer Ausdruck muss auf **kompletten** Suchstring passen.

7.1 Beispiel

- Regulärer Ausdruck: `abc`, Suchstring: “blah blah abc blub”
  - `Matcher#find`: erfolgreich
  - `Matcher#matches`: kein Match - Suchstring entspricht nicht dem Muster

8 Quantifizierung

Zeichenkette	Beschreibt
`X?`	ein oder kein “X”
`X*`	beliebig viele “X” (inkl. kein “X”)
`X+`	mindestens ein “X”, ansonsten beliebig viele “X”
`X{n}`	exakt n Vorkommen von “X”
`X{n,}`	mindestens n Vorkommen von “X”
`X{n,m}`	zwischen n und m Vorkommen von “X”

8.1 Beispiel

- `\d{5}` => “12345”
- `-?\d+\.\d*` => ???

9 Interessante Effekte

```
Pattern p = Pattern.compile("A.*A");
Matcher m = p.matcher("A 12 A 45 A");

if (m.matches())
    String result = m.group(); // ???
```

Demo: regexp.Quantifier

`Matcher#group` liefert die Inputsequenz, auf die der Matcher angesprochen hat. Mit `Matcher#start` und `Matcher#end` kann man sich die Indizes des ersten und letzten Zeichens des Matches im Eingabezeichenstrom

geben lassen. D.h. für einen Matcher `m` und eine Eingabezeichenkette `s` ist `m.group()` und `s.substring(m.start(), m.end())` äquivalent.

Da bei `Matcher#matches` das Pattern immer auf den gesamten Suchstring passen muss, verwundert das Ergebnis für `Matcher#group` nicht. Bei `Matcher#find` wird im Beispiel allerdings ebenfalls der gesamte Suchstring "gefunden" … Dies liegt am "*greedy*" Verhalten der Quantifizierer.

10 Nicht gierige Quantifizierung mit "?"

Zeichenkette	Beschreibt
`X*?`	non-greedy Variante von `X*`
`X+?`	non-greedy Variante von `X+`

10.1 Beispiel

- Suchstring "A 12 A 45 A":
  - `A.*A` findet/passt auf "A 12 A 45 A"

    normale **greedy** Variante
  - `A.*?A`
    * findet "A 12 A"
    * passt auf "A 12 A 45 A" (!)

    non-greedy Variante der Quantifizierung; `Matcher#matches` muss trotzdem auf den gesamten Suchstring passen!

11 (Fangende) Gruppierungen

`Studi{2}` passt nicht auf "StudiStudi" (!)

Quantifizierung bezieht sich auf das direkt davor stehende Zeichen. Ggf. Gruppierungen durch Klammern verwenden!

Zeichenkette	Beschreibt
`X|Y`	X oder Y
`(C)`	Gruppierung

11.1 Beispiel

- `(A)(B(C))`
  - Gruppe 0: ABC
  - Gruppe 1: A
  - Gruppe 2: BC
  - Gruppe 3: C

Die Gruppen heißen auch "fangende" Gruppen (engl.: *"capturing groups"*).

Damit erreicht man eine Segmentierung des gesamten regulären Ausdrucks, der in seiner Wirkung aber nicht durch die Gruppierungen geändert wird. Durch die Gruppierungen von Teilen des regulären Ausdrucks erhält man die Möglichkeit, auf die entsprechenden Teil-Matches (der Unterausdrücke der einzelnen Gruppen) zuzugreifen:

- `Matcher#groupCount`: Anzahl der "fangenden" Gruppen im regulären Ausdruck
- `Matcher#group(i)`: Liefert die Subsequenz der Eingabezeichenkette zurück, auf die die jeweilige Gruppe gepasst hat. Dabei wird von links nach rechts durchgezählt, beginnend bei 1(!).

  Konvention: Gruppe 0 ist das gesamte Pattern, d.h. `m.group(0)== m.group();` ...

Hinweis: Damit der Zugriff auf die Gruppen klappt, muss auch erst ein Match gemacht werden, d.h. das Erzeugen des Matcher-Objekts reicht noch nicht, sondern es muss auch noch ein `matcher.find()` oder `matcher.matches()` ausgeführt werden. Danach kann man bei Vorliegen eines Matches auf die Gruppen zugreifen.

`(Studi){2}` => "StudiStudi"

Demo: regexp.Groups

12 Gruppen und Backreferences

Matche zwei Ziffern, gefolgt von den selben zwei Ziffern

`(\d\d)\1`

- Verweis auf bereits gematchte Gruppen: `\num`

  `num` Nummer der Gruppe (1 ... 9)

  => Verweist nicht auf regulären Ausdruck, sondern auf jeweiligen Match!

  Anmerkung: Laut Literatur/Doku nur 1 ... 9, in Praxis geht auch mehr per Backreference ...

- Benennung der Gruppe: `(?<name>X)`

  `X` ist regulärer Ausdruck für Gruppe, spitze Klammern wichtig

  => Backreference: `\k<name>`

Demo: regexp.Backref

13 Beispiel Gruppen und Backreferences

Regulärer Ausdruck: Namen einer Person matchen, wenn Vor- und Nachname identisch sind.

Lösung: `([A-Z][a-zA-Z]*)\s\1`

14 Umlaute und reguläre Ausdrücke

- Keine vordefinierte Abkürzung für Umlaute (wie etwa `\d`)
- Umlaute nicht in `[a-z]` enthalten, aber in `[a-ü]`

```
"helloüA".matches(".*?[ü]A");
"azäöüß".matches("[a-ä]");
"azäöüß".matches("[a-ö]");
"azäöüß".matches("[a-ü]");
"azäöüß".matches("[a-ß]");
```

- Strings sind Unicode-Zeichenketten

  => Nutzung der passenden Unicode Escape Sequence `\uFFFF`

```
System.out.println("\u0041 :: A");
System.out.println("helloüA".matches(".*?A"));
System.out.println("helloüA".matches(".*?\u0041"));
System.out.println("helloü\u0041".matches(".*?A"));
```

- RegExp vordefinieren und mit Variablen zusammenbauen ala Perl nicht möglich => Umweg String-Repräsentation

15 Wrap-Up

- RegExp: Zeichenketten, die andere Zeichenketten beschreiben
- `java.util.regex.Pattern` und `java.util.regex.Matcher`
- Unterschied zwischen `Matcher#find` und `Matcher#matches`!
- Quantifizierung ist möglich, aber **greedy** (Default)

16 Zum Nachlesen

- Oracle Corporation (2022)

Lernziele

- k1: Wichtigste Methoden von java.util.regex.Pattern und java.util.regex.Matcher
- k2: Unterschied zwischen Matcher#find und Matcher#matches
- k2: Unterscheidung zwischen greedy und non-greedy Verhalten
- k3: Bildung einfacher regulärer Ausdrücke
- k3: Nutzung von Zeichenklassen und deren Negation
- k3: Nutzung der vordefinierten regulären Ausdrücke
- k3: Nutzung von Quantifizierern
- k3: Zusammenbauen von komplexen Ausdrücken (u.a. mit Gruppen)

Quizzes

- Quiz RegExp (ILIAS)

Challenges

In den Vorgaben finden Sie in der Klasse `Lexer` eine einfache Implementierung eines Lexers, worin ein einfaches Syntax-Highlighting für Java-Code realisiert ist.
Dazu arbeitet der Lexer mit sogenannten "Token" (Instanzen der Klasse `Token`). Diese haben einen regulären Ausdruck, um bestimmte Teile im Code zu erkennen, beispielsweise Keywords oder Kommentare und anderes. Der Lexer wendet alle Token auf den aktuellen Eingabezeichenstrom an (Methode `Token#test()`), und die Token prüfen mit "ihrem" regulären Ausdruck, ob die jeweils passende Eingabesequenz vorliegt. Die regulären Ausdrücke übergeben Sie dem `Token`-Konstruktor als entsprechendes `Pattern`-Objekt.
Neben dem jeweiligen Pattern kennt jedes Token noch eine `matchingGroup`: Dies ist ein Integer, der die relevante Matching-Group im regulären Ausdruck bezeichnet. Wenn Sie keine eigenen Gruppen in einem regulären Ausdruck eingebaut haben, nutzen Sie hier einfach den Wert 0.
Zusätzlich kennt jedes Token noch die Farbe für das Syntax-Highlighting in der von uns als Vorgabe realisierten Swing-GUI (Instanz von `Color`).
Erstellen Sie passende `Token`-Instanzen mit entsprechenden Pattern für die folgenden Token:

- Einzeiliger Kommentar: beginnend mit `//` bis zum Zeilenende
- Mehrzeiliger Kommentar: alles zwischen `/*` und dem nächsten `*/`
- Javadoc-Kommentar: alles zwischen `/**` und dem nächsten `*/`
- Strings: alles zwischen `"` und dem nächsten `"`
- Character: genau ein Zeichen zwischen `'` und `'`
- Keywords: **`package`**, **`import`**, **`class`**, **`public`**, **`private`**, **`final`**, **`return`**, **`null`**, **`new`** (jeweils freistehend, also nicht "newx" o.ä.)
- Annotation: beginnt mit `@`, enthält Buchstaben oder Minuszeichen

Die Token-Objekte fügen Sie im Konstruktor der Klasse `Lexer` durch den Aufruf der Methode `tokenizer.add(mytoken)` hinzu. Sie können Sich an den Kommentaren im `Lexer`-Konstruktor orientieren.
Sollten Token ineinander geschachtelt sein, erkennt der Lexer dies automatisch. Sie brauchen sich keine Gedanken dazu machen, in welcher Reihenfolge die Token eingefügt und abgearbeitet werden. Beispiel: Im regulären Ausdruck für den einzeiligen Kommentar brauchen Sie keine Keywords, Annotationen, Strings usw. erkennen.

Quellen

Oracle Corporation. 2022. „The Java Tutorials“. 2022. https://docs.oracle.com/javase/tutorial/.

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

> **Last modified:** 9289c1f (Remove Hugo: remove 'cbox', 2025-04-29)